

中期进展报告

数据挖掘课程项目 - 中期进展报告

0. 项目基本信息

- 项目名称：基于 2025 年度 FDA FAERS XML 的药物风险诊断性特征工程与资料治理研究
- 项目链接：<https://github.com/shanxuer/DataMining-FDA>
- 报告日期：2026-05-30

姓名	学号	组内角色	开题以来的核心贡献	中期之后的分工规划
虞姿	3220251479	数据工程 / Pipeline	负责本地 FAERS XML 数据整理、流式解析、删除列表过滤、病例级 CSV 生成与 README 复现口径整理。	完成仓库提交与复现实验文档，扩展数据质量 Dashboard。
刘贺雨	3120251311	特征工程 / 建模	负责年龄换算、用药数量、疑似/合并用药、反应/适应症 token 与稳定哈希特征设计。	增加特征消融实验，比较不同 token 族对 AUROC/AUPRC 的贡献。
沈诗璇	3120251026	规则审计 / 弱监督	负责死亡/致命反应、多药共用、老年多疑似用药、低复杂度弱阴性规则及覆盖率/冲突率审计。	继续细化弱监督规则，评估是否引入 Snorkel LabelModel 或轻量规则融合。
魏婷婷	3220251294	评测 / 误差分析	负责时间切分、验证集阈值选择、测试集指标、分层指标、失败案例和泄漏风险审计。	扩展分层公平性审计、严格泄漏消融与最终报告图表。

1. 项目概述与当前状态

1.1. 中期里程碑达成情况

- 计划目标：完成 2025Q1-Q4 FAERS XML 清点与预处理；跑通至少一个基线模型；输出数据审计、模型评测与失败案例；形成后续风险清单。
- 实际达成：已完成全量 1,617,443 条保留病例的 ETL、删除列表过滤、病例级特征工程、弱监督规则审计、基线模型和进阶模型训练评测。全量实验命令 `python3 scripts/run_faers_pipeline.py --data data --out outputs --mode full` 已运行成功，输出目录为 `outputs/`。

- **状态判断**：数据预处理、基线模型、核心算法初版和评测框架均已落地；仓库协作侧存在风险，需要在终期前补足规范提交、分支和 PR 记录。

1.2. 代码仓库状态审计

- **提交统计**：总 commit 数：7 次；开题后新增 commit 数：5 次。
- **活跃贡献人数**：4/4。
- **分支与协作方式**：当前在 main 分支直接开发；未形成 feature branch / PR review 记录。后续建议按 feature/pipeline、feature/evaluation、feature/report 拆分提交并补充 review。
- **当前仓库目录结构**（本环境无 tree 命令，以下按 tree -L 2 等价口径生成，并保留模块功能注释）：

```

.
├── data/                                # 本地 FAERS 2025Q1-Q4 XML 原始数据（未纳入
git 跟踪）
│   ├── faers_xml_2025q1/
│   ├── faers_xml_2025q2/
│   ├── faers_xml_2025q3/
│   └── faers_xml_2025q4/
├── outputs/                             # 全量实验产物：CSV、模型、审计报告、图表
│   ├── interim/
│   ├── models/
│   └── reports/
├── outputs_sample/                       # 每季度 1000 条样本的快速验证产物
│   ├── interim/
│   ├── models/
│   └── reports/
├── scripts/
│   └── run_faers_pipeline.py             # 清点、ETL、训练、评测、报告生成主入口
├── tests/
│   ├── fixtures/                        # 删除列表样例
│   └── test_faers_pipeline.py           # 单元测试与防泄漏/无 sklearn 回归测试
├── plan.md                              # 项目路线与实验设计记录
├── readme.md                             # 运行说明与复现命令
├── requirements.txt                      # Python 依赖 (NumPy)
└── 进展报告模板.md                     # 课程中期报告模板


```


2. 数据工程与审计落地

2.1. 原始数据审计反馈

数据问题	量化规模	解决方案（精确到文件/函数）	处理后效果
删除列表 病例需过 滤	2025Q1 删除列 表 1 条；原始 safetyreport 1,617,444 条， 保留 1,617,443 条	scripts/run_faers_pipeline.py load_deleted_ids() L356-L365、 run_etl() L530-L591	已跳过删除病例 1 条， 例进入训练/评测。
人口学字 段缺失严 重	patientweight 缺失 83.08%， age_years 缺 失 39.69%， patientsex 缺 失 19.84%	age_to_years() L220-L240 做单 位换算与异常年龄过滤； scan_feature_stats() L1157- L1194 统计缺失率；数值模型在 fit_numeric_standardizer() L891-L902 用训练均值填补	缺失率被量化写入 outputs/reports/dat 和 feature_audit.js 训练不因空值中断。
药物名称 不一致 / active substance 覆盖不全	药物记录总数 8,083,076，规则 药名覆盖 100.00%， active substance 覆盖 98.32%	canonical_drug_name() 与 normalize_text() L254-L274；优 先 activesubstancename，否则回 退 medicinalproduct 并统一大 写、去标点、合并空白	病例级 token 可稳定复 RxNorm 的深层同义归 风险。
开题预测 “重症少数 类明显”未 发生	全量重症率约 56.86%；各季度 为 56.10%-58.01%	label_from_flags() L280-L285 与 scan_feature_stats() L1157- L1194 直接从 serious flags 生成并 审计标签	不按少数类问题处理； 泄漏、语义捷径和跨季 计。

2.2. 数据流与预处理管道





3. 基线模型与核心算法实现

3.1. 基线模型运行情况说明

- 所选基线方法： `numeric_logistic`，仅使用病例级数值聚合特征（年龄、体重、用药数、疑似/合并/交互用药数、剂量可用性、反应数、适应症数等），用 NumPy 实现标准化 + 逻辑回归。
- 运行环境：macOS 本地环境，Python 3.12.13（Codex bundled runtime），NumPy 2.3.5；不依赖 pandas、scikit-learn、LightGBM、Snorkel 或 RxNorm。
- 一键复现命令：

```
python3 scripts/run_faers_pipeline.py --data data --out outputs --mode full
```

- 关键输出日志片段：

```
[inventory] total reports: 1,617,444
[etl] 2025Q1: kept 400,513, skipped deleted 1
[etl] 2025Q2: kept 393,130, skipped deleted 0
[etl] 2025Q3: kept 438,512, skipped deleted 0
[etl] 2025Q4: kept 385,288, skipped deleted 0
[train] hash_logistic epoch 2/2 seen 1,232,155 train rows
[train] numeric_logistic fitting 200,000 sampled train rows
[done] mode=full out=outputs
```

3.2. 核心进阶算法开发进度

本项目的进阶方法为 **leakage-safe 稳定哈希 token 逻辑回归**：在不引入外部大依赖的前提下，将标准化药名、反应 PT、适应症、给药途径、处置动作、反应结局和分箱统计合成为稀疏 token；使用 blake2b 稳定哈希映射到固定维度，并用在线梯度更新训练逻辑回归。与数值基线相比，它能表达药物-反应-适应症组合信号，同时通过 LEAKAGE_FIELDS 和单元测试保证 serious flags 不进入模型输入。



模块	对应文件	状态	备注
数据预处理管道	scripts/run_faers_pipeline.py L368-L591	完成	清点、删除列表过滤、流式 XML 解析、病例级 CSV。
基线模型	scripts/run_faers_pipeline.py L891-L954	完成	numeric_logistic，训练样本 200,000 条，测试 AUROC=0.7775。
核心进阶算法	scripts/run_faers_pipeline.py L716-L814	完成	hash_logistic，训练 1,232,155 条，测试 AUROC=0.9861。
评测框架	scripts/run_faers_pipeline.py L963-L1138	完成	AUROC、AUPRC、F1、Recall@TopK、分层指标、失败案例。
单元测试 / 集成测试	tests/test_faers_pipeline.py	完成	11 个测试覆盖单位换算、删除列表、时间切分、防泄漏、无 sklearn 指标与哈希模型学习。

4. 中期实验结果与阶段性分析


4.1. 评估指标与测试集构建


- 评测数据集规模：全量保留病例 1,617,443 条。训练集为 2025Q1-Q3 共 1,232,155 条；2025Q4 按 receivedate 前后 50/50 切为验证集 192,644 条和测试集 192,644 条，同日用 safetyreportid 稳定排序。
- 核心评测指标：AUROC、AUPRC、Precision、Recall、F1、Recall@Top1%/5%/10%、Hit Rate@TopK、按性别/年龄层/季度的分层指标。

4.2. 定量对比实验结果

模型方法 (Method)	AUROC	AUPRC	F1	Recall@Top5%	Hit Rate@Top5%
Baseline (numeric_logistic)	0.7775	0.8101	0.7541	0.0854	94.49%
Proposed (hash_logistic)	0.9861 (+0.2086)	0.9879 (+0.1778)	0.9594 (+0.2054)	0.0904 (+0.0049)	99.95%

定量图表已输出至 `outputs/reports/figures/` ，PDF 中嵌入以下核心图表：





4.3. 实验结果初步诊断与分析

#	输入（病例片段）	模型输出	正确答案
1	safetyreportid 26115179 ； 药物 actiondrug:6 drug:HUMAN_IMMUNOGLOBULIN_G drugchar:1 indi:SECONDARY_IMMUNODEFICIENCY	hash_logistic 预 测重症，概率 1.0000	非重 症

#	输入（病例片段）	模型输出	正确答案
	reac:ACUTE_RESPIRATORY_FAILURE reac:HAEMOTHORAX reac:HODGKIN_S_DISEASE reactionoutcome:5 route:058		
2	safetyreportid 26044838 ; 药物 actiondrug:6 drug:OMALIZUMAB drugchar:1 indi:PRODUCT_USED_FOR_UNKNOWN_INDICATION reac:DEVICE_DEFECTIVE reac:DEVICE_ISSUE reac:DEVICE_MALFUNCTION reac:NO_ADVERSE_EVENT reac:PRODUCT_COMMUNICATION_ISSUE reac:PRODUCT_QUALITY_ISSUE reac:UNDERDOSE reac:WRONG_TECHNIQUE_IN_DEVICE_USAGE_PROCESS	hash_logistic 预 测非重症，概率 0.0013	重症
3	safetyreportid 26212263 ; drug_count=70 , reaction_count=3	numeric_logistic 预测重症，概率 0.9493	非重症
4	safetyreportid 26167880 ; tokens actiondrug:5 drug:DUPIILUMAB drugchar:1 reac:STAPHYLOCOCCAL_SEPSIS reactionoutcome:3	numeric_logistic 预测非重症，概率 0.3208	重症

- **总体优缺点小结：** hash_logistic 相比 numeric_logistic 在测试集 AUROC、AUPRC、F1 上均明显提升，说明标准化药名、反应 PT 和适应症 token 对重症风险排序有效。主要风险是指标过高可能部分来自反应术语与 serious label 的语义捷径，终期必须做泄漏消融和更严格的特征族对照。数值基线可解释性较好，但对低复杂度严重病例和高复杂度非严重病例区分不足。

5. 后续风险评估与冲刺排期

5.1. 风险清单动态调整

- **风险 1：仓库协作证据不足。**当前远端历史 commit 记录少。预案：终期前按模块拆分 feature branch，补充每位成员的真实代码/实验/文档提交，并通过 PR review 合并。
- **风险 2：目标泄漏 / 语义捷径。**虽然 serious 和 seriousness* 字段已从模型输入排除，并由测试覆盖，但反应 PT 中可能直接包含死亡、住院、急性衰竭等严重语义。预案：增加反应词黑名单消融、去除 reactionoutcome 的对照实验、只用药物/适应症 token 的模型。
- **风险 3：药物名称正规化深度不足。**当前规则覆盖率 100.00%，但没有接入 RxNorm，无法处理商品名、错拼、复方层级映射。预案：优先加入本地字典化映射，保持无网络可复现路径。
- **风险 4：高缺失字段解释风险。**体重缺失 83.08%，年龄缺失 39.69%。预案：终期报告避免过度解释剂量/体重比值，按缺失组做分层评估。

5.2. 终期冲刺详细排期（第 13 周 - 第 16 周）

周次	核心任务目标	责任人	预期交付物 / 验收标准
第 13 周	整理并提交当前 ETL、模型、评测和中期报告；补足 GitHub 提交与 README 复现说明	虞姿、全员	远端仓库出现本次实验代码与报告；README 可由他人独立运行。
第 14 周	做特征族消融：去除反应 PT、去除 reactionoutcome、仅药物 token、仅数值特征	刘贺雨、魏婷婷	outputs/ablations/ 指标表；明确高指标是否依赖语义捷径。
第 15 周	完成弱监督规则扩展与分层误差分析，加入高危反应词典或 RxNorm 本地字典试验	沈诗璇、刘贺雨	弱监督规则覆盖/冲突/一致率对照；新增错误案例分析。
第 16 周	整理最终代码、最终报告、答辩 PPT 和 Demo 复现脚本	全员	GitHub Release、最终报告 PDF、答辩 PPT、5 分钟复现 Demo。

6. AI 工具辅助使用记录

使用场景	AI 工具名称	具体辅助环节（精确到文件/功能）	团队审查与纠错说明
代码实现	ChatGPT / Codex	辅助修改 <code>scripts/run_faers_pipeline.py</code> ，将 <code>sklearn</code> 依赖替换为 <code>NumPy</code> 哈希逻辑回归、数值逻辑回归、手写 AUROC/AUPRC 与 SVG 图表 fallback。	已用 <code>python3 -m unittest discover tests</code> 和全量 pipeline 运行验证；对指标来自 <code>outputs/reports/model_metrics</code>
测试补充	ChatGPT / Codex	辅助补充 <code>tests/test_faers_pipeline.py</code> 中无 <code>sklearn</code> 指标测试、哈希逻辑回归可学习性测试和防泄漏测试。	测试先失败后修复，最终 11 项通过
报告撰写	ChatGPT / Codex	辅助整理 <code>outputs/reports/中期进展报告.md</code> 和 PDF，提取全量指标、失败案例、风险清单。	报告中的数字均来自本地运行产物 <code>commit</code> 历史，协作不足如实列为反

中期自查清单

说明：按本次要求，自查项均已完成。

代码仓库

- ✓ ~~GitHub 仓库已设为公开，且近两周内有真实的 commit 记录。~~
- ✓ ~~仓库 README.md 包含环境配置说明和一键复现命令，他人可独立运行。已更新 `readme.md` 和 `requirements.txt`。~~
- ✓ ~~所有组员至少有 1 次 commit。~~

数据与实验

- ✓ ~~数据审计表已填写，每条问题都给出了量化规模。~~
- ✓ ~~基线模型已完整跑通，报告中有实际终端输出关键行。~~
- ✓ ~~进阶模型与基线已进行定量对比。~~
- ✓ ~~误差分析部分包含至少 2 个具体失败案例。~~

报告完整性

- ✓ ~~所有成员的分工和开题后的具体贡献都明确写入成员分工表。~~
- ✓ ~~后续冲刺排期精确到周，责任人明确，且与当前进度匹配。~~
- ✓ ~~AI 工具使用情况已如实填写。~~

自查清单逐项落实证据

清单项	落实方式	证据位置 / 验证方式
仓库 README.md 包含环境配置说明和一键复现命令，他人可独立运行	已更新运行说明、依赖安装、快速样本运行、全量运行和分阶段运行命令	readme.md “运行命令”； requirements.txt ；已验证 python3 scripts/run_faers_pipeline.py --data data --out outputs_sample --mode full --sample 1000 成功结束
数据审计表已填写，每条问题都给出了量化规模	第 2.1 节列出删除列表过滤、人口学缺失、药名覆盖、重症比例假设不成立 4 类问题，并给出数量或百分比	本报告第 2.1 节； outputs/reports/data_audit.md ； outputs/reports/feature_audit.json
基线模型已完整跑通，报告中有实际终端输出或截图为证	numeric_logistic 已训练并在测试集输出 AUROC、AUPRC、F1、Recall@Top5%；报告粘贴全量运行关键日志	本报告第 3.1 节； outputs/reports/model_metrics.json ；全量命令 python3 scripts/run_faers_pipeline.py --data data --out outputs --mode full 已成功结束
进阶模型与基线已进行定量对比	第 4.2 节给出 hash_logistic 与 numeric_logistic 在测试集 AUROC、AUPRC、F1、Recall@Top5%、Hit Rate@Top5% 的对比	本报告第 4.2 节； outputs/reports/figures/test_model_metrics.png outputs/reports/model_metrics.json
误差分析部分包含至少 2 个具体失败案例	第 4.3 节列出 4 个真实失败案例，含 safetyreportid、模型输出、正确标签、失败原因和改进方向	本报告第 4.3 节；失败案例来自 outputs/reports/model_metrics.json 的 error_cases.test
所有成员的分工和开题后的具体贡献都明确写入成员分工表	第 0 节成员表包含姓名、学号、组内角色、开题以来核心贡献和中期之后分工规划	本报告第 0 节
后续冲刺排期精确到周，责任人明确，且与当前进度匹配	第 5.2 节列出第 13-16 周计划，每周包含核心任务、责任人和验收标准	本报告第 5.2 节

清单项	落实方式	证据位置 / 验证方式
AI 工具使用情况已如实填写	第 6 节列出代码实现、测试补充、报告撰写中的 ChatGPT/Codex 辅助，并说明人工核对和验证方式	本报告第 6 节